

# 阶段一实验成果总结报告

日期: 2025年11月30日

负责人: 孙王瑜

项目: 设备故障诊断智能模型（机理模型项目）

## 1. 实验目标

本阶段旨在构建模块化的故障诊断实验平台，基于 CWRU 开源数据集，验证不同特征提取方法（FFT、机理特征、声音特征）在随机森林模型下的性能，并重点评估模型在\*\*跨工况（Cross-Load）和强噪声（High Noise）\*\*环境下的泛化能力与鲁棒性，为后续引入 Transformer 模型提供实验依据。

## 2. 实验平台架构

本阶段完成了模块化实验平台的搭建，支持灵活切换特征提取器、数据划分模式及抗噪测试。

### 2.1 系统框架图

```
graph TD
    %% 1. 数据源与加载层
    subgraph Data_Layer [数据源与预处理]
        direction TB
        Raw[CWRU 原始数据集 .mat] --> Loader[数据加载器 load_cwru.py]
        Loader --> Splitter{数据划分模块}

        Splitter -- Random --> Set1[随机划分数据集]
        Splitter -- Cross-Load --> Set2[跨负载划分数据集]

        Set2 --> Noise{抗噪测试模块}
        Noise -- SNR=0dB --> NoisySet[加噪测试集]
        Noise -- None --> CleanSet[原始测试集]
    end

    %% 2. 特征工程层
    subgraph Feature_Layer [特征工程层 core/features.py]
        direction TB
        Input(原始振动信号)

        Extractor{特征提取策略}
        Feat_FFT[FFT 特征]
        Feat_Mech[机理特征]
        Feat_Sound[声音特征]
        Feat_Hybrid[混合特征]

        Input --> Extractor
        Extractor --> Feat_FFT
        Extractor --> Feat_Mech
        Extractor --> Feat_Sound
    end
```

```
        Extractor --> Feat_Hybrid
    end

    %% 3. 模型层
    subgraph Model_Layer [模型训练层 core/models.py]
        RF[随机森林分类器]
        Eval[评估模块]
    end

    %% 层级连接
    Set1 --> Input
    CleanSet --> Input
    NoisySet --> Input

    Feat_FFT --> RF
    Feat_Mech --> RF
    Feat_Sound --> RF
    Feat_Hybrid --> RF

    RF --> Eval
```

3. 实验结果与分析

3.1 跨工况测试 (Cross-Load Evaluation)

训练集: 0, 1, 2 HP | 测试集: 3 HP

| 特征类型     | 维度   | 准确率<br>(Accuracy) | 结论                                 |
|----------|------|-------------------|------------------------------------|
| FFT (基准) | 2050 | 96.93%            | 在无噪声环境下，FFT 表现出极强的鲁棒性，几乎不受转速微变影响。  |
| 机理特征     | 12   | 68.21%            | 受转速偏差影响较大，单一机理特征难以应对工况变化。          |
| 混合特征     | 2062 | 97.21%            | <b>最优结果。</b> 机理特征作为补充信息，微幅提升了模型性能。 |

3.2 抗噪测试 (Noise Robustness)

测试集信噪比 SNR = 10dB (中等噪声) 和 0dB (强噪声)

| 特征类型   | 无噪声准确率 | 10dB 噪声准确率 | 0dB 噪声准确率 | 性能跌幅 (0dB)    |
|--------|--------|------------|-----------|---------------|
| FFT 模型 | 96.93% | 68.69%     | 36.59%    | -60.3% (严重失效) |
| 机理模型   | 68.21% | 50.46%     | -         | -             |
| 混合模型   | 97.21% | 70.23%     | 40.44%    | -56.8% (略有缓解) |

3.3 关键发现

- 1. **CWRU 数据集的“虚高”现象**：在洁净数据下，FFT 模型能达到 97% 的准确率，但这掩盖了其抗噪性差的缺陷。
- 2. **FFT 的脆弱性**：
  - 在 **10dB 中等噪声**下，FFT 模型准确率从 97% 跌至 68%，已经开始显现不稳定性。
  - 一旦引入 **0dB 强噪声**，准确率断崖式下跌至 36%，无法满足真实工业场景需求。
- 3. **机理特征的价值**：
  - 在 10dB 噪声下，混合模型 (70.23%) 依然优于纯 FFT 模型 (68.69%)。
  - 在 0dB 强噪声下，混合模型比纯 FFT 模型高出 **4%**，证明了物理先验知识在恶劣环境下的鲁棒性价值。

## 4. 下一阶段计划 (Next Steps)

基于本阶段实验暴露出的问题（抗噪性差、机理特征利用率低），下一阶段将重点开展以下工作：

- 1. **声音特征实装**：
  - 对接姚飞提供的声音转换算法，替换目前的模拟 PSD/RMS 特征，验证“以声代振”的可行性。
- 2. **引入 Transformer 模型**：
  - **目标**：解决强噪声（0dB）下准确率低的问题。
  - **方案**：利用 Transformer 的自注意力机制（Self-Attention）捕捉长距离依赖，结合去噪自编码器（Denoising Autoencoder）思想，从强噪声中恢复故障特征。
- 3. **优化机理融合**：
  - 不再简单拼接，而是将机理特征作为 Transformer 的 **Positional Encoding** 或 **Attention Mask**，深度融合物理知识。

---

文档生成时间: 2025-11-30